

Un problema de gran interés en el área de bioinformática es la predicción de precursores de microRNA (miRNAs). Estos son pequeños fragmentos de RNA que controlan múltiples procesos biológicos. Para cada especie hay un número de miRNAs que ya han sido descubiertos, pero hay una enorme cantidad de segmentos de RNA que podrían potencialmente ser miRNA pero todavía no han sido estudiados. El problema consiste entonces en tomar secuencias de RNA de un tamaño dado, calcular un vector de características asociado a dicha secuencia, y determinar si la misma puede o no ser un miRNA.

Para esta tarea en particular, se han tomado 29 tipos de virus, y de sus genomas se han extraído todos los miRNA conocidos, totalizando 237 casos de la clase positiva. Además, se han tomado 839 secuencias que se consideran negativas, es decir, se sabe con certeza que no son miRNAs. Para cada una de estas se tiene un vector de características de dimensión 28, que se proveen en el archivo virus.csv (texto separado por comas), donde los 28 primeros valores son las características y el último puede ser un 1 (es un miRNA) o un 0 (no es un miRNA).

Para evaluar el desempeño del clasificador, dado el desbalance de clases y la diferente importancia de un error para la clase positiva y la negativa, la tasa de reconocimiento (conocida también como exactitud o accuracy) no es una medida adecuada. En lugar de ello se deben utilizar otras medidas que permitan en particular evaluar la capacidad de predecir la clase positiva. Desde el punto de vista del biólogo que usará el sistema, el mismo debe detectar en lo posible todos los miRNAs que ya se conocen, en caso contrario no le tendrá confianza, dado que es esperable que prediga bien algo nuevo si no puede predecir lo ya conocido. A la vez, cuando predice un nuevo miRNA es importante que sea muy probable que realmente lo sea, porque el experimento biológico para confirmarlo definitivamente es muy caro. Es decir, además de maximizar los verdaderos positivos, es importante también minimizar los falsos positivos.

Proponga dos clasificadores, basados en arquitecturas diferentes, para intentar resolver este problema. Diseñe y realice una validación adecuada para estos datos, que le permita determinar los hiper-parámetros óptimos para cada método, y reporte el desempeño de los mismos de forma que la comparación permita seleccionar el clasificador que mejor se ajusta a los requerimiento.

Explique apropiadamente todos los criterios que haya aplicado durante la realización del trabajo (ej. por qué seleccionó determinados clasificadores, por qué usó determinada forma de validación, medidas de desempeño, etc.).